



**INSTITUT
DE LA
communication**

UNIVERSITÉ LUMIÈRE LYON 2

Sciences, Technologie, Santé

Institut de la communication

Rapport

Séries temporelles

Master 2 Machine Learning for Artificial Intelligence

Sous le thème :

**Prévoir la consommation électrique de
la France, la veille à 14 h pour le
lendemain**

Présenté par :

- 1. OUEDRAOGO Martine**
- 2. NGOM Khadim**

Année universitaire 2026-2027

Table des matières

1	Question, données et règle opérationnelle	2
2	Protocole expérimental et prévention des fuites	2
3	Méthodes et hypothèses testées	3
4	Résultats hors échantillon	4
5	Audit critique : où le système échoue-t-il?	4
6	Usage de l'IA : traçabilité, contrôle et décisions	6
7	Conclusion et accès aux livrables	6
	Annexe — Reproduire et contrôler les résultats	8

À retenir. À 14 h (heure de Paris), nous prévoyons les 24 consommations horaires du lendemain à partir de RTE, d'observations SYNOP et du calendrier, *sans connaître la météo future*. Sur 723 journées de test (2024–2025), le modèle linéaire avec température observée **M2 atteint 1 331 MW de MAE**, contre **3 205 MW** pour la référence B0. Le gradient boosting M3 est proche (1 349 MW) : l'écart n'est pas significatif (test de Diebold–Mariano, $p = 0,60$). La météo réelle du lendemain n'est utilisée que pour une *borne non déployable* (1 044 MW).

Accès immédiat : [code, README, tests et résultats \(GitHub\)](#) | [application interactive \(Streamlit\)](#).

1 Question, données et règle opérationnelle

Pour chaque jour d'origine J , la prévision est émise à **14 h, heure de Paris**, et fournit $\hat{y}_{J+1,h}$ pour $h = 0, \dots, 23$. La consommation RTE est disponible jusqu'à la tranche 12–13 h de J : la tranche 13–14 h n'est pas considérée publiée à 14 h. La météo est observée jusqu'à 13 h et les caractéristiques calendaires de $J + 1$ sont connues à l'avance. En conséquence, la consommation à la même heure du jour J est utilisable pour $h \leq 12$; au-delà, on remonte à $J - 1$. Cette règle s'applique aussi aux résidus employés par M4.

Source	Construction	Point de vigilance
RTE éCO2mix	Consommation nationale, demi-heure agrégée à l'heure, stockage UTC	Heure d'été/hiver, versions consolidées ou définitives
Météo-France SYNOP	Mesures toutes les 3 h, 38 stations continentales retenues pour la température nationale	Trous imputés causalement, anomalies, absence de météo prévue
Calendrier	Jour, mois, fériés, ponts, vacances A/B/C	Variables connues avant la prévision

Le nettoyage météo mobilise les stations voisines au même instant puis les observations passées ; les règles sont calibrées sur l'apprentissage. Les jours de 23 ou 25 heures liés aux changements d'heure restent dans l'historique, mais sont exclus de la notation des journées à 24 valeurs. La température nationale est une moyenne régionale pondérée par la consommation historique ; ce choix est comparable aux moyennes simples sur la validation.

2 Protocole expérimental et prévention des fuites

Découpage chronologique : apprentissage 2016–2022, validation 2023 (sélection des variables et réglages), test final 2024–2025 (723 jours communs), puis contrôle complémentaire janvier–juin 2026. Les modèles sont réestimés sur une fenêtre croissante : trimestriellement en validation, mensuellement en test. Les jours du premier confinement sont exclus de l'entraînement selon une décision préalable, même si une analyse ultérieure a montré qu'ils pouvaient aider en 2023.

Un contrôle automatique reconstruit les variables après avoir remplacé les observations postérieures à 14 h par des valeurs aberrantes : les prédicteurs doivent rester




FIGURE 1 – Historique de consommation et dépendance à la température.

identiques. Deux fuites artificielles ont servi à tester ce contrôle. Une fuite effective de M4 sur l'heure 13 a été corrigée avant la comparaison finale. **Réserve** : les consommations historiques consolidées sont plus propres que les publications en temps réel ; les performances peuvent donc être optimistes en production.

3 Méthodes et hypothèses testées

Code	Méthode	Question étudiée
B0	Persistance disponible à 14 h	La consommation récente suffit-elle ?
B1	Même jour, semaine précédente	Le cycle hebdomadaire suffit-il ?
B2	Moyenne de quatre semaines	Le lissage améliore-t-il la référence ?
M1	Régression : retards + calendrier	Que gagnent les variables explicatives simples ?
M2	M1 + sept variables de température passée	La météo <i>observée</i> ajoute-t-elle de l'information ?
M3	HistGradientBoosting, mêmes variables que M2	Les non-linéarités améliorent-elles la prévision ?
M4	M1 + correction AR(1) des résidus	Les erreurs récentes sont-elles prévisibles ?
Borne	M2 + température <i>réelle</i> de $J + 1$	Quel gain théorique avec une météo parfaite ?

Chaque modèle prédictif est estimé **séparément pour les 24 heures cibles** : en 2023, cette stratégie a mieux fonctionné qu'un modèle unique intégrant l'heure comme covariable (environ 1 548 contre 2 096 MW). Pour M1–M3, les retards admissibles, effets calendaires et transformations de température sont définis en amont. M3 a été sélectionné parmi quatre configurations prédéfinies ; le réglage retenu est 15 feuilles, 300 itérations et un taux d'apprentissage de 0,05. Pour M4, l'AR(1) a été préféré aux

variantes ARMA testées sur 2023.




FIGURE 2 – Ablations sur la validation 2023 : contribution des retards et de la météo.

4 Résultats hors échantillon

Toutes les méthodes sont évaluées sur les **mêmes journées complètes**. La MAE est $MAE = \frac{1}{N} \sum_i |y_i - \hat{y}_i|$; l'analyse comprend aussi RMSE, MAPE, biais, énergie quotidienne et pointe.

Méthode	MAE 2023	MAE 2024-25	MAE 2026	MAPE test
	MW			
B0 — persistance	3 313	3 205	3 147	6,4 %
B1 — semaine	3 468	3 337	4 054	6,2 %
B2 — 4 semaines	4 162	3 649	4 497	6,9 %
M1 — passé + calendrier	1 547	1 584	1 780	3,0 %
M2 — M1 + météo	1 500	1 331	1 424	2,6 %
M3 — boosting	1 580	1 349	1 524	2,6 %
M4 — M1 + AR(1)	1 520	1 591	1 747	3,0 %
Borne météo parfaite	1 251	1 044	974	2,1 %

M2 réduit la MAE de **58,5 %** par rapport à B0 et de **16,0 %** par rapport à M1 sur le test. Le gain de M2 face à M1 est significatif ($p < 0,001$), contrairement à la différence M2-M3 ($p = 0,60$ pour la MAE). M2 est retenu comme compromis *simplicité-interprétabilité-stabilité*, notamment en hiver; M3 est compétitif, parfois meilleur en été et sur l'énergie journalière. Le test bonus 2026 soutient ce choix sans constituer une nouvelle validation de réglages.

5 Audit critique : où le système échoue-t-il ?

Disponibilité. Les retards de consommation, observations de température et variables calendaires sont construits à partir de l'information connue à 14 h. La température réelle du lendemain n'est **jamaïs** employée par les modèles opérationnels; la borne météo parfaite est un scénario contrefactuel. L'audit détaillé figure dans [la documentation du dépôt](#).

Valeur de la complexité. Les retards apportent l'essentiel du gain (M1 contre B0). La météo améliore M1 sur le test; M3 n'améliore pas significativement M2, et M4




FIGURE 3 – Comparaison des modèles sur validation, test et période complémentaire.

n'apporte pas de gain. Le bénéfice d'un modèle complexe n'est donc pas présumé : il est mesuré.

Jour	M2 (MW)	Borne (MW)	Diagnostic
05/01/2025	8 207	959	Redoux brutal non anticipé : limite de l'information météo.
24/11/2024	7 732	746	Redoux brutal : même limite des données disponibles.
24/12/2024	7 075	5 612	Veille de Noël : événement calendaire mal représenté, limite du modèle.

Robustesse et biais. M2 est moins précis en hiver (MAE 2 017 MW) qu'en été (940 MW), et l'erreur augmente à partir de 13 h lorsque le retard le plus proche devient indisponible. Les modèles surestiment la consommation depuis 2023 (biais M2 : +518 MW sur le test), possiblement à cause de la rupture de niveau liée à la sobriété énergétique. Cette hypothèse n'a pas été utilisée pour ajuster le test a posteriori.




FIGURE 4 – MAE de M2 selon l'heure cible : impact de la coupure à 14 h.

Usage déconseillé sans vigilance : redoux et vagues de froid rapides, fériés tombant le week-end, fêtes de fin d'année, changement durable du niveau de consommation. Les priorités sont l'intégration de véritables prévisions météo publiées avant 14 h, une adaptation aux niveaux récents et une validation glissante sur plusieurs années.

6 Usage de l'IA : traçabilité, contrôle et décisions

L'IA a été un **outil d'assistance**, non une source de résultats scientifiques. Notre méthode de travail était : formuler la question, examiner la proposition, exécuter les scripts ou tests, lire les sorties, puis décider. Les exemples ci-dessous distinguent ce qui a été observé de ce qui reste à confirmer. Le **journal d'IA** permet de retrouver les échanges et les décisions.

Exemple 1 — Proposition conservée après vérification (Martine, non-fuite). *Tâche :* garantir que les prédicteurs ne dépendent pas d'observations postérieures à 14 h. *Proposition :* reconstruire les variables après perturbation des valeurs futures et vérifier leur invariance. *Contrôle :* introduction volontaire de deux fausses fuites ; la première injection, dans une fonction non utilisée, n'a pas été détectée, puis le contrôle a été corrigé pour cibler le calcul réellement exécuté. *Décision :* conserver le test d'invariance, avec cette limite explicitée.

Exemple 2 — Proposition rejetée (Martine, séparation temporelle). *Tâche :* intégrer le contrôle complémentaire de 2026. *Proposition :* prolonger la période de données du projet jusqu'en 2026. *Vérification :* comparaison avec la décision de gel du test 2024–2025 et contrôle que les données historiques 2016–2025 restent inchangées. *Décision :* conserver 2026 dans un jeu bonus distinct, sans réoptimiser les modèles.

Exemple 3 — Erreur détectée et corrigée (Khadim, vérification logique). *Tâche :* vérifier le tableau de bord après synchronisation du dépôt. *Observation :* une exécution de pytest a retourné 494 tests réussis et 12 échecs du tableau de bord dus à `ModuleNotFoundError: No module named 'plotly'`. *Contrôle :* lecture des traces d'erreur pour séparer une dépendance absente d'un défaut des modèles statistiques. *Décision :* signaler la dépendance et demander une nouvelle exécution ciblée ; **nous ne déclarons pas ces 12 tests réussis** sans sortie ultérieure.

Autres interventions de Khadim. L'IA a aussi servi à préparer et discuter la sélection de M3, la disponibilité des variables météo et calendaires, l'interprétation de la comparaison M2–M3, la synchronisation GitHub et le déploiement Streamlit. La synchronisation a été vérifiée par une exécution manuelle réussie ; le déploiement a nécessité de remplacer une URL de dépôt par le script `app/tableau_de_bord.py`. Ces tâches sont utiles pour la reproductibilité, mais ne remplacent pas les trois cas de vérification ci-dessus.

Répartition du travail. Martine a principalement pris en charge la consommation, les références et les modèles linéaires ; Khadim les variables météo/calendaires, l'étude du boosting et le tableau de bord. Les règles temporelles, la confrontation des résultats, l'audit et la rédaction finale relèvent du travail commun.

7 Conclusion et accès aux livrables

Le résultat principal est qu'une régression horaire intégrant le calendrier, les retards et la météo *déjà observée* atteint 1 331 MW de MAE sur 2024–2025, avec un protocole à 14 h explicitement audité. La complexité du boosting n'apporte pas de gain

Les 3 pires journées de M2 (test 2024-2025)




FIGURE 5 – Trois journées d’erreur élevée : courbes observées et prédites.

statistiquement établi; l’absence de prévision météo du lendemain reste le principal frein. Les analyses des journées atypiques, du biais et des fuites rendent ce constat plus informatif qu’un classement de scores seul.

Pour examiner le projet : ouvrir l’application, puis **consulter le dépôt** pour les scripts, résultats et tests. Le README est la référence pour reproduire la chaîne sur un nouvel environnement.

Annexe — Reproduire et contrôler les résultats

Dépôt : <https://github.com/MarteOued/Projet-series-temporelles>. Cloner le dépôt, créer un environnement Python, installer les dépendances décrites dans le README, puis suivre les étapes de préparation des données, de construction des variables, d'évaluation et de génération du rapport. Les fichiers bruts RTE et SYNOP peuvent nécessiter un téléchargement préalable selon les instructions du dépôt. Ne pas utiliser les données du test pour régler les modèles.

```
git clone https://github.com/MarteOued/Projet-series-temporelles.git
cd Projet-series-temporelles
python -m venv .venv
# Activer .venv selon votre systeme, puis installer les dependances
# en suivant le README du depot.
python -m src.rte          # preparation RTE (voir prerequis README)
python -m src.rapport      # generation des resultats et figures
python -m pytest -q        # controles automatisees
streamlit run app/tableau_de_bord.py
```

Important : l'exécution intégrale des commandes sur un environnement vierge n'a pas été vérifiée pour cette édition du rapport. Les commandes supplémentaires et les noms des modules intermédiaires doivent être pris dans le README actuel, et non déduits du présent document.

Vérifications à effectuer avant remise : contrôler le chemin des modules du README courant, l'installation de plotly, la réussite des tests du tableau de bord, la présence des six figures et le fonctionnement de l'application publique. Les résultats numériques cités ici sont ceux du protocole rapporté; ils ne constituent pas une nouvelle exécution indépendante.

Documents utiles : [audit des variables](#); [journal IA](#); [RTE éCO2mix](#); [Météo-France SYNOP](#).

Lecture rapide de l'application : ouvrir le lien Streamlit depuis la première page, sélectionner la période et le modèle disponibles, examiner les courbes observées/prédites, puis confronter les erreurs affichées au tableau du rapport. L'interface peut évoluer; les intitulés exacts des contrôles sont ceux de la version déployée.